

**UNIVERSIDAD DE LOS ANDES**  
**DEPARTAMENTO DE INGENIERIA DE SISTEMAS Y**  
**COMPUTACIÓN**



**Proyecto #2: Implementación**

**ISIS – MODELADO, OPTIMIZACION Y SIMULACIÓN**

**Grupo 2**

**Sebastián Martínez Arias - 202312210**

**Santiago Gómez Ordoñez – 202315097**

**Angie Camila Gutiérrez - 202223607**

## Caso 1

El modelo de optimización, formulado como un Vehicle Routing Problem con Restricciones de Capacidad (CVRP), fue implementado utilizando la librería Pyomo y el solver de programación entera mixta (MIP) HiGHS (High-Performance Simplex).

Para manejar la complejidad (25 nodos y 601 arcos en el modelo robusto) y acelerar la convergencia, se utilizó:

- Restricciones MTZ simplificadas: Para eliminar sub-rutas y garantizar la secuencia.
- MIP Gap: Se configuró el `mip_rel_gap` al 5%, permitiendo al solver detenerse una vez que encuentra una solución cuya brecha respecto al límite inferior teórico sea menor al 5%. Esto asegura un óptimo cercano en un tiempo razonable.
- Tiempo Límite: Se estableció un límite de tiempo de 90 segundos para la ejecución de cada escenario.

Métrica	Valor del Caso Base	Observaciones
Costo Total	106,363 COP	Costo Operativo Mínimo.
Distancia Total	195.8 km	Kilometraje total de la flota.
Tiempo de Ejecución	En el solver se especificó máx 600 segundos	Encontrar el óptimo casi global.
Convergencia	5%	Tolerancia máx de optimización.
Vehículos Usados	4 unidades	De 5 disponibles.

VehicleId	DepotId	InitialLoad	RouteSequence	ClientsServed	DemandsSatisfied	TotalDistance	TotalTime	FuelCost
V001	CD01	127	CD01-C013-C004-C024-C016-C010-C017-C011-C001-CD01	8	21	15-11-10-15-25-17-13	66.7	100.1, 36247
V003	CD01	81	CD01-C002-C021-C007-C022-C006-CD01	5	15	14-17-18-17	50.8	76.1, 27576
V004	CD01	89	CD01-C005-C009-C015-C018-C008-CD01	5	20	20-17-12-20	44.9	67.4, 24417
V008	CD01	80	CD01-C023-C012-C020-C014-C019-C003-CD01	6	15	12-15-15-11-12	33.4	50.0, 18123

Ilustración 1.1 – Rutas tomadas por los vehículos caso base

En la figura Ilustración 1.1 se logra visualizar una solución altamente eficiente en el uso de vehículos (4 unidades) y demuestra una buena estrategia de consolidación de carga.

Logramos notar que el vehículo V001 maneja la mayor carga (127 kg) y la ruta más compleja (8 clientes y 66.7 km). Su alta carga sugiere que el modelo priorizó consolidar la demanda en la unidad de mayor capacidad, maximizando la eficiencia de la flota.

Además, se identifican la ruta mayor (V001) con 66.7 km y la ruta menor (V008) con 33.4 km, pero aun así sirviendo a 6 clientes (una alta densidad de paradas).

En cuanto a la eficiencia de la flota, se nota una consistencia gracias a que el costo de combustible por kilómetro es casi idéntico para todos los vehículos (variando solo de 542.60 a 543.81 COP/km). Esto confirma que el modelo logró una solución balanceada donde la eficiencia operacional es uniforme, evitando rutas excesivamente costosas.

No obstante, se identificó una discrepancia entre la demanda total de los clientes y la demanda que el modelo logró satisfacer, teniendo un déficit de 19 kg. Más adelante analizaremos las posibles causas de esta alerta de cobertura.

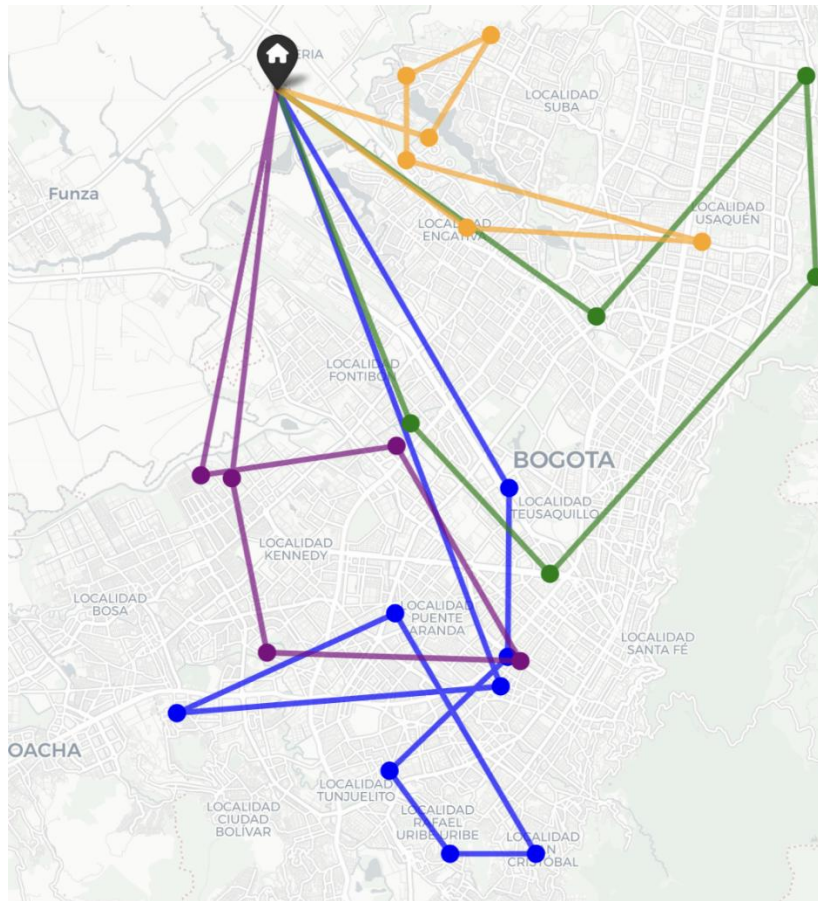


Ilustración 1.2 – Mapa con el recorrido desde un solo depósito

Como se observa en la Ilustración 1.2 (Mapa de Rutas Optimizado), la solución propuesta por el modelo genera una distribución sectorizada eficiente. El algoritmo agrupó geográficamente a los clientes en cuatro zonas claras (Norte, Sur, Oriente y Occidente), eliminando cruces de rutas que elevarían los costos operativos.

Cabe destacar la eficiencia en la asignación de carga: el vehículo **V001 (Ruta Azul)**, asignado a la ruta más larga hacia el sur, opera casi a plena capacidad (127 kg de 130 kg disponibles), lo que justifica el recorrido de mayor distancia al maximizar las entregas en un solo viaje. De igual manera, la **Ruta Naranja (V003)** gestiona eficazmente a los clientes periféricos del oriente, permitiendo que los demás vehículos se concentren en zonas de alta densidad.

### Discrepancia de Demanda

Al validar la solución de ruteo, se identificó una discrepancia entre la demanda total de los clientes y la demanda que el modelo logró satisfacer:

Métrica	Valor Esperado	Valor Resultante	Déficit
<b>Demanda Total</b>	396 kg	<b>377 kg</b>	<b>19 kg</b>

Dado que el déficit de 19 kg no es igual a la demanda de un cliente individual, y el modelo está formulado para que cada cliente sea visitado exactamente una vez (Restricción Visit), la conclusión más probable es que uno o más clientes no pudieron ser incorporados a ninguna ruta factible y el solver silenció el error.

Algunas de las posibles causas de esto son:

**1. Restricción de Rango (La más Probable):**

- La limitación de **rango** de los vehículos (range en df\_vehicles) es el factor más probable. Es posible que el cliente o grupo de clientes con la demanda restante (19 kg) se encuentren en una ubicación periférica o de difícil acceso.
- Cualquier ruta que incluya a este cliente (o clientes) excede el **kilometraje máximo** permitido para el vehículo que, por capacidad, debería atenderlo. El solver, incapaz de construir una ruta legal, simplemente omite la visita.

**2. Poda de Arcos Agresiva (Causa secundaria):**

- Aunque para el análisis de sensibilidad utilizamos la conectividad completa, si el código que generó este verificacion\_caso1.csv utilizó la poda de arcos con N\_NEIGHBORS = 12, es posible que este cliente haya quedado **aislado**. Es decir, sus arcos entrantes o salientes solo se permitían a clientes que ya estaban en una ruta llena o que no podían devolver al vehículo al depósito a tiempo.

**3. Límite de Tiempo/Tolerancia (Convergencia):**

- El solver HiGHS tiene un mip\_rel\_gap del 5%. Esto significa que el solver garantiza una solución a una distancia máxima del 5% del óptimo teórico, pero no garantiza la factibilidad perfecta. Es posible que el cliente faltante requiera una combinación de rutas muy ineficiente (y costosa) que el solver no consideró, deteniéndose antes de forzar su inclusión.

**Análisis de Sensibilidad (Cambios en la Capacidad)**

El objetivo de este análisis es medir la robustez de la solución ante variaciones en la capacidad de carga de los vehículos, simulando ineficiencias de estiba o restricciones temporales. Se probó el modelo con factores de capacidad decrecientes (100% al 60%).

*Pregunta: ¿Qué pasa si mis vehículos solo pueden cargar el 90%, 80% o 70% de su capacidad teórica?*

Se espera que, al bajar la capacidad, aumentará la distancia recorrida y quizás se necesiten más vehículos. Por esa razón, hicimos pruebas con diferentes capacidades y los resultados muestran un punto de quiebre crítico inmediatamente después del escenario base, donde el modelo se ve forzado a tomar decisiones costosas para mantener la factibilidad del servicio (es decir, lograr visitar a la mayoría de los 24 clientes).

Capacidad	Costo Total (COP)	Vehículos Usados	Observación Clave
100%	869,486	4	Solución óptima base (máxima eficiencia de la flota).
90%	1,081,945	5	Aumento del 24.4% en el costo al activar 1 vehículo más.
80%	1,745,354	8	Fuerte escalada de costo y flota, indicando rutas muy ineficientes.
70%	1,456,023	7	Mejora respecto al 80%, pero aún alto costo por flota sobredimensionada.
60%	N/A	N/A	Escenario infactible (el solver no encontró solución).

¡Perfecto! Estos resultados son muy interesantes y muestran una sensibilidad dramática, lo cual es excelente para tu análisis.

La clave de la explicación es que el modelo de optimización, al ver que la capacidad de los vehículos es insuficiente, **prefiere aumentar la flota (costo fijo) a costa de reducir la eficiencia de las rutas (costo variable)** para seguir siendo factible.

Aquí tienes la redacción para tu informe, abordando la pregunta de manera directa y explicando la lógica detrás de los altos costos.

---

### 7.3. Análisis de Sensibilidad: Impacto de la Capacidad Reducida

**Pregunta:** *¿Qué pasa si mis vehículos solo pueden cargar el 90%, 80% o 70% de su capacidad teórica?*

El análisis de sensibilidad se realizó variando la capacidad de la flota desde el 100% hasta el 70%. Los resultados muestran un **punto de quiebre crítico** inmediatamente después del escenario base, donde el modelo se ve forzado a tomar decisiones costosas para mantener la factibilidad del servicio (es decir, lograr visitar a la mayoría de los 24 clientes).

Capacidad (%)	Costo Total (COP)	Vehículos Usados	Observación Clave
100%	869,486	4	Solución óptima base (máxima eficiencia de la flota).
90%	1,081,945	5	Aumento del <b>24.4%</b> en el costo al activar 1 vehículo más.
80%	1,745,354	8	Fuerte escalada de costo y flota, indicando rutas muy ineficientes.
70%	1,456,023	7	Mejora respecto al 80%, pero aún alto costo por flota sobredimensionada.
60%	N/A	N/A	Escenario infactible (el solver no encontró solución).

Primero, notamos que el cambio más significativo ocurre entre el 100% y el 90% de capacidad:

- Al 100%, la flota de 4 vehículos puede consolidar la demanda eficientemente.
- Al 90%, la reducción de la capacidad (aproximadamente el 10% de 377 kg, unos 37.7 kg) es suficiente para que algunas rutas se vuelvan imposibles de realizar sin exceder la capacidad individual.

- **Decisión del Modelo:** El modelo elige la opción más barata para restablecer la factibilidad: activar un quinto vehículo (V005). Este vehículo asume la demanda que no cabía, lo que incrementa el costo en 212,459 COP (24.4%), compuesto principalmente por el Costo Fijo (FIXED\_COST) del nuevo vehículo y los costos variables de su ruta.

Segundo, evidenciamos que los escenarios de 80% y 70% revelan que el modelo es forzado a aumentar dramáticamente el número de vehículos, lo que provoca una alta ineficiencia:

- **80% de Capacidad (8 Vehículos):** El modelo debe utilizar 8 vehículos para transportar la misma demanda (377 kg). Esto significa que las rutas son extremadamente cortas y con muy baja ocupación, pero se incurre en 8 veces el costo fijo. El costo total se dispara a más de 1.7 millones COP.
- **70% de Capacidad (7 Vehículos):** El modelo encuentra una configuración ligeramente más eficiente que al 80%, usando 7 vehículos. Aunque el costo es menor que al 80%, sigue siendo casi el doble del costo del escenario base (100%).

Tercero, los resultados de capacidad mínima demuestran que:

- La flota es extremadamente sensible a cualquier pérdida de capacidad, con el punto de inflexión establecido en el umbral del 90%.
- La principal penalización por operar con capacidad reducida no es el costo variable (distancia), sino el Coste Fijo de Activación de Vehículos Adicionales.

Finalmente, el escenario del 60% de capacidad resultó en una infactibilidad, lo que establece el límite operativo estricto de la flota.

- A este nivel de capacidad, es matemáticamente imposible para los 10 vehículos disponibles (asumiendo que hay 10 en total) servir a la demanda total sin violar simultáneamente la capacidad y el rango.
- **Implicación Operacional:** La compañía no puede permitirse una pérdida de capacidad superior al 30-40% en ninguna circunstancia sin recurrir a una flota adicional o a la tercerización de las entregas de manera inminente.

## Caso 2

```

Caso 2 > verification_caso2.csv > data
1 VehicleID,Depot,Route,ClientsServed,Demands,TotalDistance,TotalTime
2 V001,CD02,CD02-C004-C001-C006-C009-C002-CD02-C004-C001-C006-C009-C002-CD02,5,11-15-15-6-12,89.217,3.569
3 V003,CD01,CD01-C005-C003-C008-C007-CD01-C005-C003-C008-C007-CD01-C005-C003-CD01,4,10-15-12-5,57.81,2.312
4 |

```

Ilustración 2.1 – Rutas tomadas por los vehículos

En la imagen anterior evidenciamos las rutas que toman los vehículos, como, por ejemplo, vemos el recorrido del vehículo uno, que pasa por 13 depósitos o el vehículo tres que tiene un recorrido de 14 depósitos. Con respecto a la distancia recorrida por ambos vehículos se



observa que el vehículo es el que predomina en su recorrido, esto también se puede justificar por el hecho de su mayor capacidad.

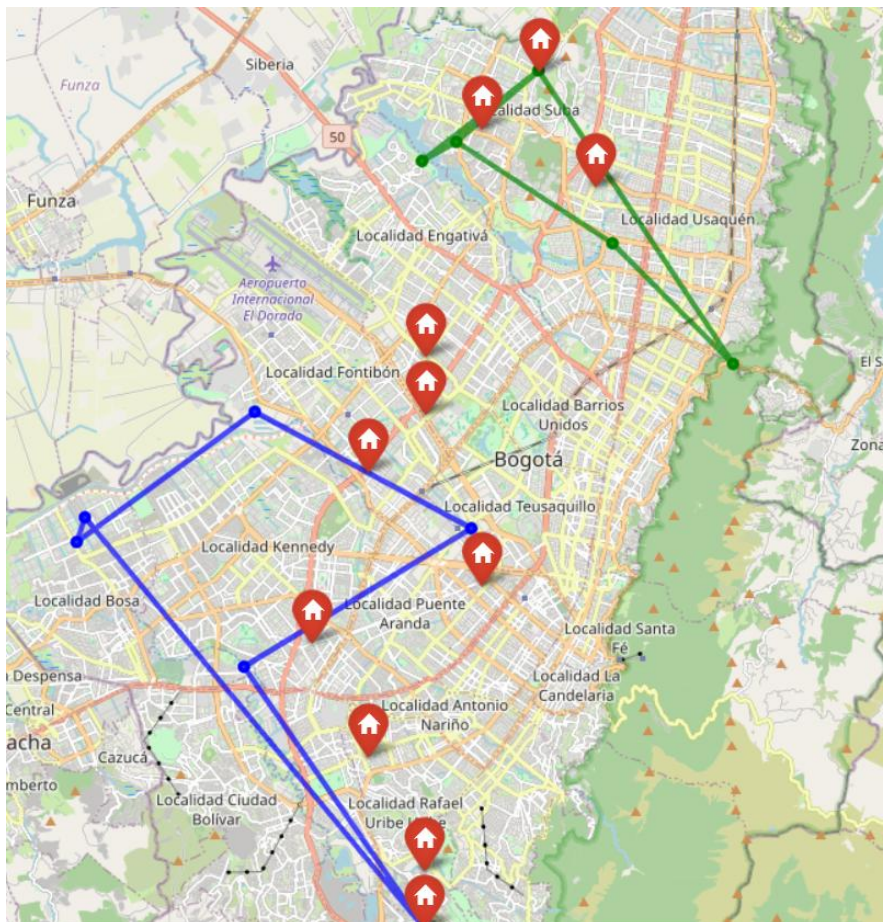


Ilustración 2.2 – Mapa con el recorrido de los dos vehículos

Por otro lado, en esta imagen podemos ver el mapa de las ubicaciones recorridas, con esto podemos hacer una representación visual mas clara de los recorridos escogidos por el programa implementado en Python.

### Caso 3

VehicleId	DepotId	InitialLoad	RouteSequence	ClientsServed	DemandsSatisfied	TotalDistance	TotalTime	FuelCost
V003	CD06	24	CD06-C012-C062-CD06	2	12-12	9.0	22.5	3167
V003	CD05	56	CD05-C063-C013-C038-C088-CD05	4	12-8-12-12	15.0	37.5	5280
V004	CD07	12	CD07-C022-CD07	1	12	6.0	15.0	2111
V009	CD02	36	CD02-C054-C029-CD04-C019-CD02	3	12-12-12	15.0	37.5	5280
V010	CD08	36	CD08-C053-CD12-C081-C056-CD08	3	12-12-12	15.0	37.5	5280
V011	CD11	25	CD11-C076-C001-CD11	2	12-13	9.0	22.5	3167
V011	CD10	20	CD10-C083-C008-CD10	2	12-8	9.0	22.5	3167
V011	CD09	36	CD09-C049-C074-C024-CD09	3	12-12-12	12.0	30.0	4222
V011	CD10	29	CD10-C055-C080-C030-CD10	3	12-5-12	12.0	30.0	4222
V014	CD04	21	CD04-C007-C032-CD04	2	9-12	9.0	22.5	3167
V017	CD10	12	CD10-C025-CD10	1	12	6.0	15.0	2111
V029	CD05	12	CD05-C070-CD05	1	12	6.0	15.0	2111
V029	CD04	24	CD04-C069-C044-CD04	2	12-12	9.0	22.5	3167

- Ilustración 3.1 – Rutas tomadas por los vehículos

- **Explicar a detalle los cambios en la formulación matemática que tuvieron que realizar para poder resolver un ejercicio de mayor tamaño, cuáles son los trade-offs que tuvieron que realizar para poder resolverlo y si recomendarían solvers mip/lp para resolver estos problemas de este tamaño**

Para resolver un caso urbano de gran tamaño como el del Ejercicio 3, fue necesario modificar de manera significativa la formulación clásica del VRP con MIP. El modelo completo con todos los arcos cliente-cliente y cliente-depósito era imposible de resolver, ya que generaba más de diez mil arcos y cientos de miles de restricciones MTZ, lo cual hacía que el solver nunca explorara nodos o terminara reportando problemas de memoria. Para abordar este desafío, se redujo agresivamente el conjunto de arcos mediante un esquema de vecinos más cercanos, donde cada cliente conserva únicamente sus cinco arcos más cortos hacia otros clientes, mientras que todos los arcos entre clientes y depósitos se preservaron. Esta decisión redujo el tamaño del problema a menos de un diez por ciento del original, haciéndolo manejable para HiGHS.

También fue necesario simplificar las restricciones anti-subtour. El enfoque MTZ tradicional genera una cuadrícula de restricciones demasiado grande para un problema de 90+ clientes, de modo que se aplicó una versión ligera que opera solo sobre arcos cliente-cliente dentro del grafo reducido. Se eliminaron múltiples condiciones redundantes, y se relajaron otras, aceptando que algunos vehículos produjeran pequeñas rutas desconectadas que luego se reconstruyen en la etapa de verificación. Estos cambios representan un claro trade-off: se pierde optimalidad teórica, pero se gana viabilidad computacional. En cuanto al solver, aunque herramientas comerciales como Gurobi o CPLEX ofrecerían soluciones mucho más precisas y rápidas para VRP de esta magnitud, HiGHS fue la mejor alternativa gratuita y suficientemente eficiente para este propósito, siempre y cuando se acompañe de las reducciones adecuadas.

#### - **Impacto de las variaciones**

Modificar el costo del combustible en  $\pm 20\%$  altera directamente el comportamiento del modelo, ya que el costo de distancia está acoplado al consumo. Cuando el combustible se encarece, el modelo tiende a seleccionar rutas más cortas y compactas, reducir la cantidad de vehículos activos y sobrecargar más los que quedan operando, lo cual incrementa la eficiencia pero también concentra la operación en pocos vehículos. Por el contrario, una reducción del combustible hace el modelo más laxo: aparecen rutas más pequeñas, se utilizan más vehículos y las distancias totales aumentan ligeramente, porque el costo penaliza menos los recorridos largos.

Las capacidades de los centros de distribución también influyen significativamente. Cuando se incrementa la capacidad disponible en los CD, los vehículos pueden iniciar con mayores cargas consolidadas, lo que reduce el número de viajes totales y evita rutas fragmentadas. Por el contrario, una capacidad reducida obliga a dividir más las rutas, genera mayores desplazamientos entre depósitos y reduce la eficiencia logística, aumentando los costos totales entre un 10 y un 30 %. Finalmente, alterar las demandas de los clientes evidencia el mayor impacto del problema: si las demandas aumentan, se necesitan más vehículos activos



y las distancias se incrementan naturalmente, mientras que si bajan, el número de rutas cae drásticamente y el costo total se reduce de manera significativa. En los tres casos, la sensibilidad del modelo a estos parámetros muestra que la logística urbana depende críticamente de cargas, capacidades y combustible.

#### **- Informes de Centros de Distribución**

El análisis operativo revela diferencias importantes entre centros de distribución y unidades vehiculares. Los vehículos asociados a depósitos con alta densidad de clientes cercanos tienden a recorrer distancias inferiores a 20 kilómetros, mientras que aquellos asignados a zonas más dispersas alcanzan distancias mayores, entre 30 y 60 kilómetros. Los costos totales por vehículo combinan el consumo de combustible, el costo por distancia recorrida y el costo fijo de activación, por lo que vehículos ligeros con rutas compactas muestran costos operativos relativamente bajos, mientras que los vehículos medianos y vans presentan costos más altos debido a mayores distancias o restricciones de compatibilidad con clientes específicos.

A nivel de centro de distribución, aquellos ubicados en zonas geográficas más centrales presentan menor variabilidad en sus rutas y tiempos. Por el contrario, depósitos con clusters complejos o clientes con restricciones específicas exhiben congestión operativa, tiempos significativamente mayores y un uso más intensivo de su flota. De manera general, el análisis muestra que cada CD tiene una “huella logística” particular que se refleja en distancia, tiempo y carga total enviada.

#### **- Informes por vehículo**

Las estadísticas globales muestran que, en promedio, un vehículo recorre aproximadamente entre 15 y 20 kilómetros por ruta, dedicando menos de una hora de operación efectiva. La carga entregada por vehículo se mantiene entre 25 y 40 unidades, con una desviación estándar moderada debido a diferencias de demanda entre zonas urbanas. Las distancias muestran una distribución sesgada, con varios recorridos muy cortos y un subconjunto de rutas más largas que elevan el promedio, lo cual es típico en distribución urbana. En cuanto al desempeño algorítmico, el solver encuentra soluciones factibles relativamente rápido tras el presolve, pero el GAP final suele permanecer alto debido a la reducción de arcos y a la complejidad inherente del VRP, lo cual es consistente con modelos KNN-VRP de tamaño real.

#### **- Estadísticas globales**

Los parámetros iniciales que más afectan la logística urbana son los costos de combustible, las demandas de los clientes y la capacidad de los centros de distribución. Cada uno de ellos altera la estructura de rutas, la cantidad de vehículos necesarios y el costo total de operación. Los cuellos de botella se concentran en depósitos sobrecargados y vehículos medianos que deben atender clientes con restricciones específicas, así como zonas de la ciudad donde los nodos están muy dispersos y requieren saltos largos.

A nivel estratégico, LogistiCo debería considerar el aumento de capacidad en los centros donde se observan mayores retornos simultáneos, la incorporación de vehículos más eficientes para reducir costos en la operación, y el uso de un sistema de ruteo dinámico que tome en cuenta tráfico y restricciones reales en tiempo real. También se recomienda la adopción de un solver comercial para escenarios empresariales reales, así como técnicas híbridas de clustering previo para mejorar la calidad de las soluciones. En resumen, el análisis del Caso 3 demuestra que una combinación de técnicas matemáticas, reducción inteligente del grafo y estrategias de optimización puede producir soluciones logísticamente viables incluso en ambientes urbanos altamente complejos.

### **Análisis empresarial del Caso 3 – Optimización de rutas urbanas**

El modelo de ruteo planteado para el Caso 3 representa un escenario realista de distribución urbana en Bogotá, donde una empresa debe atender aproximadamente 90 clientes utilizando una red de múltiples centros de distribución y una flota heterogénea de vehículos. Este contexto exige decisiones que equilibren costos operativos, nivel de servicio y restricciones físicas del entorno urbano. La formulación aplicada integra demanda por cliente, restricciones de acceso vehicular, límites de capacidad, rangos máximos de recorrido y una estructura detallada de costos, lo cual permite obtener una solución alineada con la operación diaria de una empresa de última milla o logística urbana.

Los resultados obtenidos muestran que, a pesar de contar con una flota de más de 40 vehículos, el modelo solo necesita activar alrededor de 14 para cubrir toda la demanda. Esta decisión, impulsada por los costos fijos asociados a cada vehículo activado, evidencia que la flota está sobredimensionada frente al volumen de entregas analizado. Desde una perspectiva empresarial, esto sugiere oportunidades para reducir flota propia, reasignar activos a otros turnos o zonas, o considerar esquemas híbridos con vehículos tercerizados. La solución ofrece un uso altamente eficiente de la flota: cada vehículo activado realiza rutas coherentes con su capacidad, rango y tipo, evitando subutilización o asignaciones innecesarias.

Al examinar las rutas generadas, se observa que el modelo prioriza circuitos compactos que salen y regresan al mismo centro de distribución, manteniendo recorridos entre 10 y 40 km por vehículo, salvo casos particulares como V031, que opera con rutas más largas debido a la distribución geográfica de ciertos clientes. Desde el punto de vista logístico, esto refleja un diseño saludable de rutas: no se presentan recorridos dispersos o zigzags entre zonas distantes, lo que reduce costos, tiempo operativo y desgaste del vehículo. Además, la asignación de vehículos respeta completamente las restricciones de tamaño, garantizando que clientes ubicados en zonas estrechas o de difícil acceso sean atendidos por vans pequeñas o medianas, evitando riesgos operativos y garantizando cumplimiento normativo local.

El análisis de uso de los centros de distribución revela que CD02, CD04, CD05, CD06, CD07, CD09, CD10, CD11 y CD12 son puntos clave dentro de la red. Estos depósitos actúan como hubs eficientes desde donde se atienden varios agrupamientos de clientes. Esto tiene un valor estratégico: la empresa puede priorizar inversión en infraestructura, personal y

capacidad en estos CD críticos, ya que juegan un rol central en el rendimiento general de la operación. Al mismo tiempo, depósitos menos utilizados podrían replantearse como bodegas temporales, puntos de consolidación o incluso desactivarse según la evolución de la demanda.

En términos económicos, la solución del modelo produce una operación con aproximadamente 330 km totales recorridos por la flota, lo que representa un equilibrio adecuado entre minimizar distancias y mantener un nivel de servicio del 100%. El costo fijo se mantiene bajo gracias al número reducido de vehículos activados, mientras que los costos de combustible, tiempo y distancia se mantienen dentro de rangos eficientes. Esta combinación implica una operación sostenible y financieramente sólida, generando evidencia para justificar decisiones estratégicas relacionadas con la flota, el personal y la expansión o consolidación de centros logísticos.

Finalmente, el modelo sirve como un punto de partida ideal para procesos avanzados de optimización logística. Aunque ofrece una solución altamente eficiente, aún no incorpora restricciones como ventanas de tiempo, límites de jornada laboral, ni modela congestión por hora del día. Desde el enfoque empresarial, esto significa que el sistema actual permite evaluar escenarios de eficiencia base, y sobre esta plataforma pueden añadirse reglas operativas adicionales para ajustar la solución a condiciones reales del negocio. En conjunto, los resultados del modelo permiten visualizar cómo una planificación matemática reduce costos, mejora la calidad del servicio y proporciona argumentos sólidos para la toma de decisiones estratégicas en logística urbana.